



APACHE SOLR

Busqueda de texto completo con Lucene



¿QUE ES APACHE SOLR?

Motor de busqueda de texto completo de codigo abierto, construido sobre Apache Lucene. Corre como un servidor HTTP independiente al que se le envian documentos para indexar y consultas para buscar.



CONCEPTOS CLAVE

- Coleccion: conjunto de documentos indexados (como una tabla)
- Esquema: define los campos y como se analiza cada uno
- Shard: fragmento de una coleccion (SolrCloud, para escalar)

¿COMO FUNCIONA? — PROCESO

1

DEFINIR ESQUEMA

Se declaran los campos de los documentos y como se analizara cada uno.

2

INDEXAR DOCUMENTOS

`solr.add(documentos)` envia los datos y `solr.commit()` los hace buscables.

4

CONSULTAR

`solr.search("query")` devuelve documentos ordenados por relevancia (BM25).

3

CONSTRUIR INDICE

Solr tokeniza el texto y arma un indice invertido, igual que Oracle Text.

TIPOS DE CONSULTAS QUE SE PUEDEN REALIZAR

- Palabra/frase: `texto:"dato"`
- Por campo: `titulo:python`
- Booleana: `python AND NOT java`
- Comodin/fuzzy: `pyth*`, `pythom~1`
- Rango: `precio:[10 TO 50]`
- Facetas: contar por categoria
- Highlighting: resaltar coincidencia
- Ordenar: `sort=fecha desc`
- Geoespacial: por ubicacion
- Autocompletar: sugerencias

EJEMPLO PARA CORRER EN LA COMPUTADORA

```
import pysolr
solr = pysolr.Solr('http://localhost:8983/solr/practica_ri')
solr.add([{'id': '1', 'titulo': 'Apache Solr'}])
solr.commit()
resultados = solr.search('titulo:Solr')
for doc in resultados:
    print(doc['titulo'])
```

`solr_practica.py`